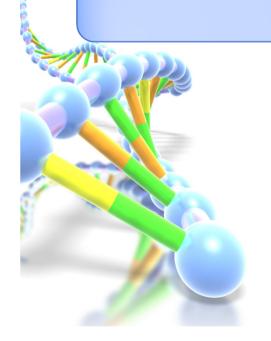


Les 09 – Microarray's en differentiële gen expressie (2)

Emile Apol





Institute for Life Science & Technology

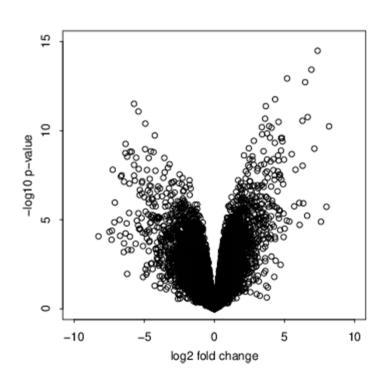
LES 09

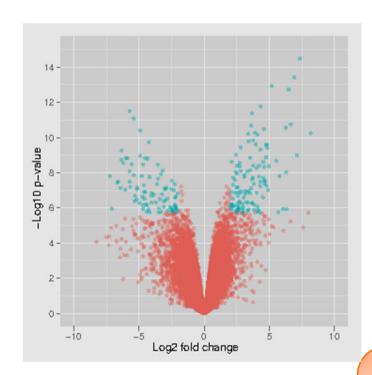
- O Doe meer met DEG's:
 - Volcano plot
 - "Effect size (η^2) plot"
- Algemene aanpak MA analyse: ANOVA
 - Meerdere factoren
 - Confounding
 - Experimentele opzet (DOE)

MICROARRAY ANALYSE: STAPPENPLAN

- Background correctie
- Log transformatie
- Normalisatie (bijv. loess)
- Toetsen op DEG's:
 - t-toets, 1-way ANOVA, ...
 - Wilcoxon's toets, Kruskall-Wallis toets, ...
- Aanpassen p-waarden voor multiple toetsing
- Clustering van DEG's:
 - Hiërarchisch clusteren
 - k-means
 - Principale Componenten Analyse (PCA)
- Toetsen op functionaliteit genen binnen clusters

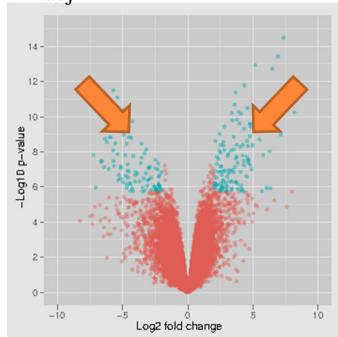
- Wat zijn "biologisch relevante" DEG's?
 - Kleine p-waarde
 - Grote (absolute) log fold change |M|





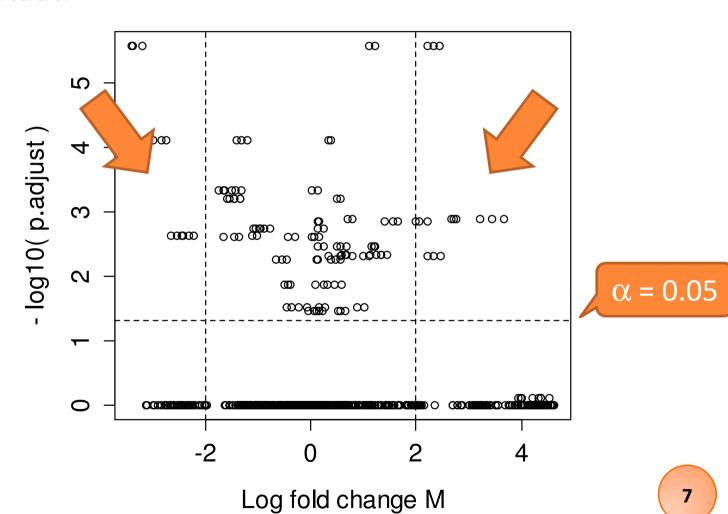


- o Plot ${}^{10}\log(p\text{-waarden})$, evt. met multiple toets correctie, als functie van M-waarden.
- "Biologisch interessante" genen:
 - bijv. |M| > 2
 - bijv. $^{10}\log(p_{\rm adj}) > ^{10}\log(0.05)$



• Snelle manier om volcano-plot te maken uit dataframe M (met enkel M-waarden, per regel één gen), en een vector pVec en/of pVec.adjust met (aangepaste) p-waarden uit t-toets/ANOVA/... per gen:

• Resultaat:



• Gewone punten **zwart**, maar **rood** als $p_{\rm adj}$ < 0.05 en |M| > 2 :

```
# make colors red for special points
colors.ALL <-1 + (pVec.adjust.ALL < 0.05 & abs(logFold.ALL) > 2)
plot(-log10(pVec.adjust.ALL) ~ logFold.ALL,
     xlab="Log fold change M",
                                                              00
                                                                  യ
     ylab="- log10(p.adjust)",
     col=colors.ALL)
                                       - log10( p.adjust
abline(h=-log10(0.05), lty=2)
abline(v=-2, lty=2)
                                           \mathfrak{C}
abline(v=2, lty=2)
                                                               ത്തത്ത താ
                                           \mathcal{O}
                                           0
                                                          0
                                                    Log fold change M
```

KLEUREN IN R

- Verschillende manieren om in R kleur aan te geven:
 - ol = c("black", "red")
 - col = c(1, 2)
 - col = rainbow.colors(12)
- O Logicals: T = TRUE = 1, F = FALSE = 0, dus

```
# make colors red for special points colors.ALL <- 1 + (pVec.adjust.ALL < 0.05 & abs(logFold.ALL) > 2)
```

levert normaal 1 (= "black") maar als $p_{\rm adj}$ < 0.05 en |M| > 2 , dus 1 + (T & T) = 1 + T = 2 (= "red"); dit maakt een vector van 1'en en 2'en...

- p-waarde geeft statistische significantie (> toeval?)
- o |M|-waarde geeft "biologische" significantie: effect sterkte, aribraire grens |M| > 2
- Bij t-toetsen en 1-way ANOVA ook statistische definitie van effect sterkte: η^2 (eta kwadraat) = practische significantie

$$\eta^2 \equiv \frac{SS_{\text{tussen}}}{SS_{\text{tot}}} = \frac{SS_{\text{tussen}}}{SS_{\text{tot}} + SS_{\text{binnen}}}$$

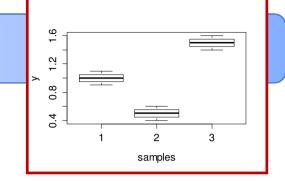
1-way ANOVA

$$\eta^2 \equiv \frac{SS_{\text{tussen}}}{SS_{\text{tot}}} = \frac{t^2}{t^2 + df}$$

t-toets

EFFECT STERKTE: η^2

- Voorbeeld: 1-way ANOVA



```
> summary(aov(y ~ samples))
           Df Sum Sq Mean Sq F value Pr(>F)
               1.50
                       0.75 75 5.69e-05
samples
Residuals
                0.06
                       0.01
```

$$\eta^2 = \frac{SS_{\text{tussen}}}{SS_{\text{tot}} + SS_{\text{binnen}}} = \frac{1.50}{1.50 + 0.06} = 0.96$$

Dit betekent dat 96% van alle variatie in de data komt door verschillen tussen de groepen (de andere 4% is "ruis")

• Voorbeeld: 2-sample *t*-toets

> t.test(y ~ samples, var.equal=T)

Two Sample t-test

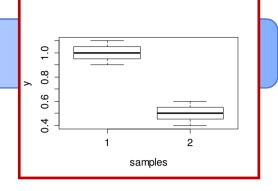
data: y by samples

t = 6.1237, df = 4, p-value = 0.003602

alternative hypothesis: true difference in means is not equal to 0

$$\eta^2 = \frac{t^2}{t^2 + df} = \frac{6.1237^2}{6.1237^2 + 4} = 0.90$$

Dit betekent dat 90% van alle variatie in de data komt door verschillen tussen de groepen (de andere 10% is "ruis")



- Wanneer is een effect (verschil tussen biologische samples) groot?
- Vuistregel (Cohen, 1988):

η^2 waarde	Effect sterkte
0.01	zwak effect
0.10	matig effect
> 0.25	sterk effect
1	perfecte relatie

NB. Vaak gaan statistische significantie (p-waarde < 0.05) en practische significantie (effect sterkte) samen, soms niet!

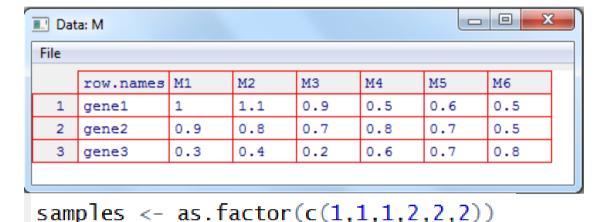
13

- o Voorbeeld van R functie om p-waarde en η^2 per gen te berekenen: t-toets (2-sample, Welch, gepaard)
- o Input:
 - M-waarden per gen (\mathbf{x} = rij matrix)
 - Vector g (factor) met groepslevels

```
matrixTTest <- function(x, g, ...){

g <- as.factor(g)
Q <- t.test(x ~ g, ...)
p.value <- Q$p.value
eta2 <- Q$statistic^2/(Q$statistic^2 + Q$parameter)
a <- c()
a[1] <- p.value
a[2] <- eta2
names(a) <- c("p-value","eta2")
return(a)
}</pre>
```

O Data:



Resultaat:

```
> apply(M, 1, matrixTTest, g=samples, var.equal=T)
             gene1
                  gene2
                                   gene3
p-value 0.00219213 0.2745766 0.008049893
                                              anonieme argumenten
       0.92452830 0.2857143 0.857142857
eta2
> apply(M, 1, matrixTTest, g=samples, var.equal=F)
              gene1
                       gene2
                                    gene3
p-value 0.004833894 0.2846272 0.008049893
                                              anonieme argumenten
        0.938697318 0.3169399 0.857142857
eta2
> apply(M, 1, matrixTTest, g=samples, paired=T)
                      gene2
              gene1
p-value 0.005063324 0.05719096 0.05719096
                                                        15
eta2
        0.989898990 0.88888889 0.88888889
```

- Voorbeeld van R functie om p-waarde en η^2 per gen te berekenen: 1-way ANOVA
- o Input:
 - M-waarden per gen (\mathbf{x} = rij matrix)
 - Vector g (factor) met groepslevels

```
matrix1WayANOVATest <- function(x, g){
    g <- as.factor(g)
    Q <- summary(aov(x ~ g))[[1]]
    p.value <- Q$Pr[1]
    SS.g <- Q$Sum[1]; SS.tot <- sum(Q$Sum); eta2 <- SS.g/SS.tot
    a <- c()
    a[1] <- p.value
    a[2] <- eta2
    names(a) <- c("p-value","eta2")
    return(a)
}</pre>
```

O Data:

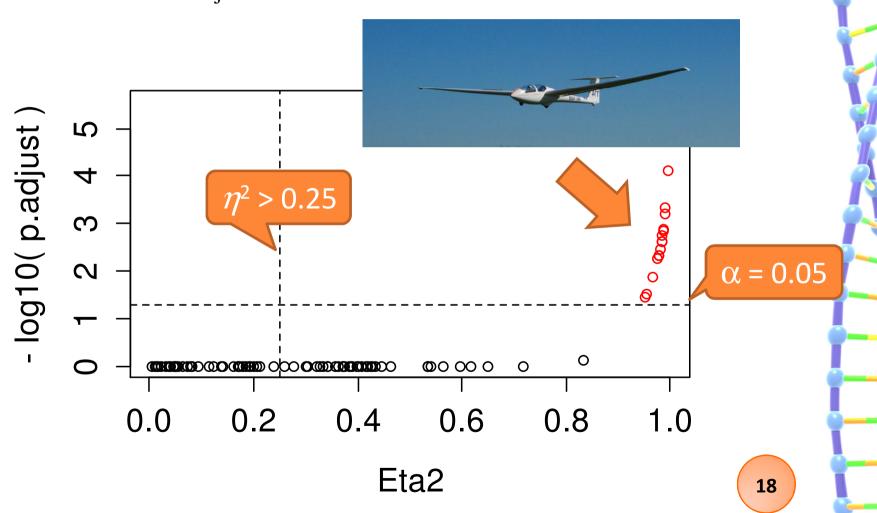
File							
	row.names	M1	M2	МЗ	M4	M5	M6
1	gene1	1	1.1	0.9	0.5	0.6	0.5
2	gene2	0.9	0.8	0.7	0.8	0.7	0.5
3	gene3	0.3	0.4	0.2	0.6	0.7	0.8

• Resultaat:

samples
$$\leftarrow$$
 as.factor(c(1,1,2,2,3,3))

ALTERNATIEF VOLCANO: GLIDER PLOT?

o Plot - 10 log (p_{adj}) vs. η^2 voor alle genen:



ALGEMENE ANALYSE MA'S: ANOVA

- Veel "ad hoc" preprocessings stappen, o.a. normalisatie, kunnen door systematische aanpak automatisch worden gedaan:
- ANOVA analyse (Jackson-groep: Churchill, Kerr, Cui)



Gary Churchill



Kathleen Kerr



Xiangqui Cui

DIFFERENTIËLE GEN EXPRESSIES: 1 GEN, 2 SAMPLES

• Data format 1: r replica's van M' waarden per gen:

Gene	M'_1	M' ₂	•••	M'_i	•••	M'_r
gene 1	0.51	0.34	•••	0.55	•••	0.44
gene 2	-0.14	-0.31	•••	0.11	•••	-0.27
gene g	0.78	0.85	•••	0.69	•••	0.75
•••						
gene G	1.15		•••	0.66	•••	0.91

1-sample *t*-toets voor $\mu = 0$

DIFFERENTIËLE GEN EXPRESSIES: 1 GEN, >2 SAMPLES

o Data format 1: k samples, r replica's j van $M_{ij} = \log(T_{ij})$ waarden per gen per sample i:

		sample 1				sample <i>k</i>		
Gene	M' ₁₁		M'_{1r}	•••	M'_{k1}	•••	M' _{kr}	
gene 1	0.51	•••	0.34	•••	0.55	***	0.44	P
gene 2	-0.14	•••	-0.31	•••	0.11	•••	-0.27	
gene g	0.78		0.85		0.69	•••	0.75	}
•••		1						
ge	1.	way AN			0.66	•••	0.91	
			21					

ANOVA: PER GEN OF HELE MA?

- Zoeken naar DEG's: t-toets of 1-way ANOVA per gen
- Model per gen (sample s, replica k):

$$M_{s,k} = \mu + S_s + \varepsilon_{s,k}$$

- $aov(x \sim S)$ # S = factor met sample nrs.
- Alternatief: 2-way ANOVA op *hele microarray*:
- Model (gen g, sample s, replica k):

$$M_{g,s,k} = \mu + S_s + G_g + (SG)_{s,g} + \varepsilon_{g,s,k}$$

aov (x ~ S + G + S:G) # G = factor met gen nrs.

DIFFERENTIËLE GEN EXPRESSIES: 2-WAY ANOVA

o Data format: k samples, r replica's j van $M_{ij} = \log(T_{ij})$ waarden per gen per sample i:

		sample 1				sample <i>k</i>		Y
Gene	M ′ ₁₁		M'_{1r}	•••	M'_{k1}		M'_{kr}	
gene 1	0.51	•••	0.34	•••	0.55	* * 10	0.44	P
gene 2	-0.14	•••	-0.31	•••	0.11	•••	-0.27	
gene g	0.78	•••	0.85		0.69	•••	0.75	}
•••								
gene G	1.15	•••	0.45		0.66	•••	0.91	
							23	

2-WAY ANOVA

• 2-way ANOVA model:

"Ruis"

$$M_{g,s,k} = \mu + S_s + G_g + (SG)_{s,g} + \mathcal{E}_{g,s,k}$$

Gemiddelde log fold change: "normalisatie"

Gemiddelde effect van een biologisch sample *s*

Interactie

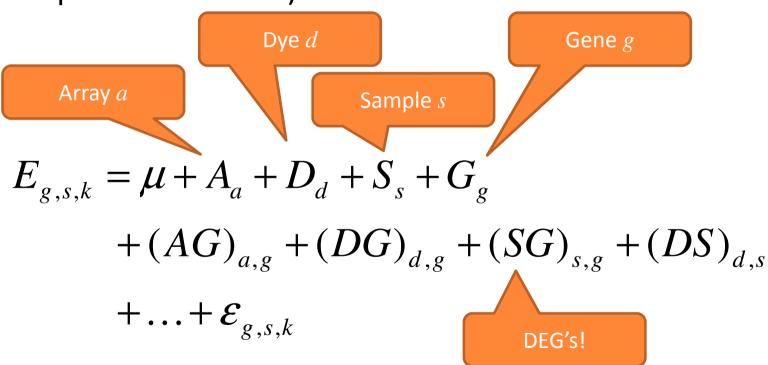
(versterkend/verzwakkend effect) tussen sample s en gen g

Gemiddelde effect van een gen g

o DEG's zijn genen g waarvoor de interactie term $(SG)_{s,g}$ in het model significant is!

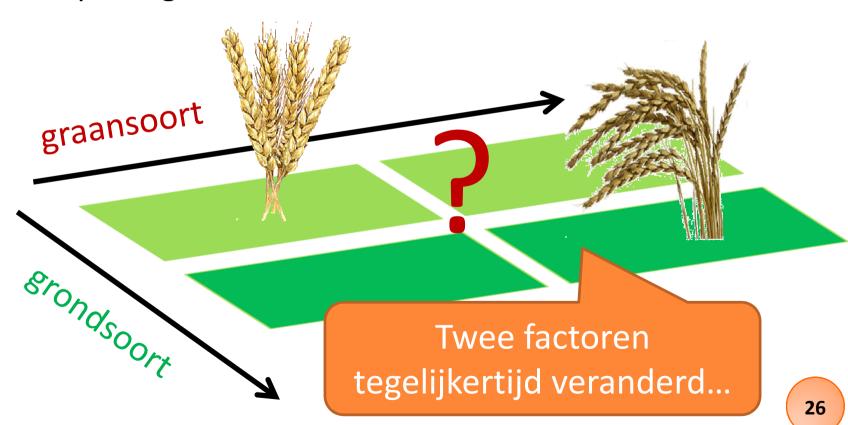
MULTI-WAY ANOVA

 2-way ANOVA model is ook verder uit te breiden naar meer factoren (= verklaringen voor verschillen in log expressie waarden):



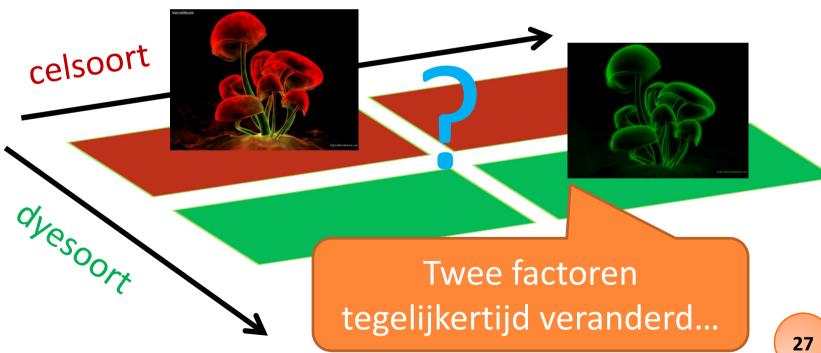
CONFOUNDING

 Plantenveredelingsexperiment: 2 soorten graan op 2 soorten grond. Wat is het effect van graansoort op opbrengst?



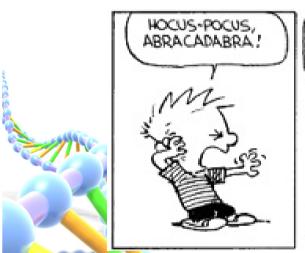
CONFOUNDING

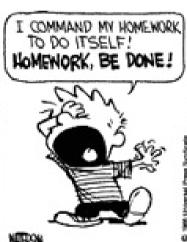
 Microarray experiment: 2 soorten cellen met 2 soorten dye. Wat is het effect van celsoort op fluorescentie intensiteit?



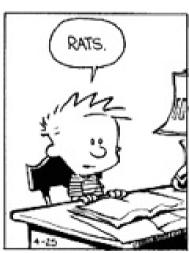


Jullie kunnen nu de opdrachten van les 13 maken











Institute for Life Science & Technology