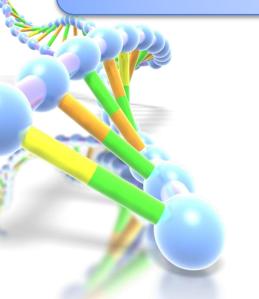


Les 13 – DEG's en clustering (2)

Emile Apol





Institute for Life Science & Technology


LES 13

- O Hiërarchisch clusteren: hclust
 - opties plotten clusters
 - subclusters: cutree

visualisatie: matplot, image, heatmap,

heatmap.2


kleurpalet in R



MICROARRAY ANALYSE: STAPPENPLAN


- Background correctie
- Log transformatie
- Normalisatie (bijv. loess)
- Toetsen op DEG's:
 - t-toets, 1-way ANOVA, ...
 - Wilcoxon's toets, Kruskall-Wallis toets, ...
- Aanpassen p-waarden voor multiple toetsing
- Clustering van DEG's:
 - Hiërarchisch clusteren
 - k-means
 - Principale Componenten Analyse (PCA)
- o Grafische weergave: heatmap, vulcano plot, ...

 Voorbeeld: 10 M-waarden van DEG's in 2 situaties S1 en S2 (bijv. tijdstippen, gehalten trigger molecuul X, etc.)



	row.names	S1	52	
1	gene 1	8	7.8	
2	gene 2	5.5	4.9	
3	gene 3	8.1	8.3	
4	gene 4	1.5	1.3	
5	gene 5	1.5	2.1	
6	gene 6	4.6	4.9	
7	gene 7	10.2	10.5	
8	gene 8	9.5	7.5	
9	gene 9	3.5	4.5	
10	gene 10	8.9	9.4	


 Voorbeeld: 10 M-waarden van DEG's in 2 situaties S1 en S2 (bijv. tijdstippen, gehalten trigger molecuul x, etc.)



	row.names	S1	52
1	gene 1	8	7.8
2	gene 2	5.5	4.9
3	gene 3	8.1	8.3
4	gene 4	1.5	1.3
5	gene 5	1.5	2.1
6	gene 6	4.6	4.9
7	gene 7	10.2	10.5
8	gene 8	9.5	7.5
9	gene 9	3.5	4.5
10	gene 10	8.9	9.4

- Clustering van dataframe/matrix M met 2 samples per row, en 10 genen (=rows):
- Berekenen van afstandsmatrix:
 - dMat <- dist(M, method="euclidean")
- Bereken van clustering:
- Plotten van dendrogram:
 - plot(clust)


Resultaat: Cluster Dendrogram



d.E hclust (*, "average")

PLOTTEN VAN CLUSTERS


oplot(clust) = plot(clust, hang=0.1):




dist(x) hclust (*, "complete") dist(x) hclust (*, "complete") dist(x) hclust (*, "complete")


SUBCLUSTERS: CUTREE()

- Opsplitsen van clustering clust in subclusters
- Gegeven aantal subclusters k:
 - sC.2<-cutree(clust, k=2)
 - sC.3<-cutree(clust, k=3) \frac{5}{9}
 - sC.4<-cutree(clust, k=4)</pre>
- Resultaat: subcluster nummer per gen



Cluster Dendrogram





SUBCLUSTERS: CUTREE()

O Dataframe M:

```
      M1
      M2
      M3
      M4
      M5

      gene1
      5.1
      5.6
      6.2
      5.7
      5.5

      gene2
      4.9
      4.5
      4.3
      4.4
      4.7

      gene3
      10.1
      10.7
      11.9
      11.1
      10.5

      gene4
      8.9
      8.5
      7.8
      7.5
      7.1

      gene5
      2.3
      2.5
      2.7
      3.4
      3.9

      gene6
      2.4
      4.1
      5.8
      7.7
      8.9
```

- Data uit dataframe M selecteren voor 1^e subcluster van de 4:
 - M[sC.4 == 1,]


```
M1 M2 M3 M4 M5
gene1 5.1 5.6 6.2 5.7 5.5
gene3 10.1 10.7 11.9 11.1 10.5
```

SUBCLUSTERS: CUTREE()

- Opsplitsen van clustering clust in subclusters
- Gegeven hoogte h in dendrogram:
 - sC<-cutree(clust, h=1.0)
 - sC<-cutree(clust, h=.75) 5
 - sC<-cutree(clust, h=.50)</p>
- Resultaat: subcluster nummer per gen

Cluster Dendrogram


0.



MATPLOT()

 \circ Plotten van een dataframe **M** met G rijen (genes) en n samples


 matplot plot kolommen van matrix als losse datasets



MATPLOT()

- Naast matplot(), die een nieuwe plot aanmaakt, zijn er ook:
 - matpoints () # tekent punten in bestaande plot
 - matlines() # tekent lijnen in bestaande plot
- Bijvoorbeeld:

```
matplot(t(MA), type="n", xlab="Sample", ylab="Log fold change M")
matlines(t(MA), col=1:ncol(MA), lty=1)
```




IMAGE()

- Maken van een kleurenmap van dataframe M:
 - X <- as.matrix(M)</p>

image wil matrix, geen dataframe!

• image(X) = image(X, col=heat.colors(12)



KLEURPALET IN R

- Voorgedefinieerde kleurpaletten (n kleuren):
 - heat.colors(n=)
 - topo.colors(n=)
 - terrain.colors(n=)
 - rainbow(n=)
- Eigen palet maken: RGB kleuren (Red/Green/Blue)
 - rood: rgb(c(255,0,0), maxColorValue=255)
 - groen: rgb(c(0,255,0), maxColorValue=255)
 - blauw: rgb(c(0,0,255), maxColorValue=255)
 - WIT: rgb(c(255,255,255), maxColorValue=255)
 - vart: rgb(c(0,0,0), maxColorValue=255)

KLEURPALET VOOR MA'S: LET OP

- Breng de lezer niet in verwarring:
 - NIET: rainbow (onlogische kleuren!)
 - WEL: 1 of 2 kleuren


- Denk aan lezers met kleurenblindheid:
 - NIET: rood+groen, groen+bruin, groen+blauw, blauw+grijs, blauw+paars, groen+grijs, groen+zwart, licht groen+geel
 - WEL: blauw+oranje, blauw+rood, blauw+bruin

MA.colors()




• Eigen definitie van kleurpalet (met *n* kleuren):


```
MA.colors <- function(n=12){
  colorRampPalette(c("green", "black", "red"), space="rgb")(n)
}</pre>
```




HANDIGE KLEURPALETTEN


Blauw + rood:





Blauw + oranje:






HEATMAPS

- o Image van dataframe met enkel- (gen) of tweevoudige (gen & sample) clustering van dataframe **M**:
 - X <- as.matrix(M)</p>
 - heatmap(X, col=MA.colors())
- o heatmap gebruikt de default methoden voor dist()
 en hclust() functies!

heatmap voer ook default een *scaling normalisatie* uit per gen!



DEFAULTS VAN FUNCTIES DIST() EN HCLUST()

- \circ Dataframe/matrix **M** met G rijen (genes) en n samples
- o Distances:
 - d <- dist(M)</pre>
 - default: method="euclidean"
- o Distance object d
- O Hiërarchisch clusteren:
 - clust <- hclust(d)</pre>
 - default: method="complete"

EIGEN DIST EN HCLUST FUNCTIES

- o dist functies, werkend op matrix x (rij = gen):
 - Euclidisch:

 - Manhattan:

 - Pearson:
 - myDist.P <- function(x) { as.dist(1 cor(t(x))) }</pre>
 - "Absolute" Pearson:
 - myDist.AP <- function(x) { as.dist(1 abs(cor(t(x)))) }</pre>

EIGEN DIST EN HCLUST FUNCTIES

- o hclust functies, werkend op dist object x:
 - Single linkage:
 - myHclust.S <- function(x) {
 hclust(x, method="single") }</pre>
 - Complete linkage:
 - myHclust.C <- function(x) {
 hclust(x, method="complete") }</pre>
 - Average linkage:
 - myHclust.A <- function(x) {
 hclust(x, method="average") }</pre>


HEATMAPS MET WILLEKEURIGE CLUSTER METHODEN

- Definieer eerst eigen dist en hclust functies, bijv.

 - myHclust.A <- function(x) {
 hclust(x, method="average") }</pre>
- Roep heatmap aan met eigen functies, zonder scaling:
 - X <- as.matrix(M)</p>

EIGEN HEATMAPS

Default heatmap (Euclidisch/Complete) vs.
 Pearson/Average, allen met optie scale="none":




Euclidisch/Complete

Pearson/Average

HEATMAPS MET ENKELE CLUSTERING


- Je kunt clustering van genen en/of samples uitzetten:
 - geen clustering samples: Colv=NA
 - geen clustering genen: Rowv=NA



HEATMAP.2()


- In package gplots
 - package (gplots)
 - library(gplots)
 - X <- as.matrix(M)
 - heatmap.2(X, col=MA.colors(),
 scale="none",
 hclustfun=myHClust.A,
 distfun=myDist.P, symbreaks=T,
 trace="none")


Zorgt ervoor dat het midden van het kleurpalet overeenkomt met de waarde X = 0



HEATMAP.2()


Ook hier alleen clustering op genen of samples, via
 Colv=NA of Rowv=NA:



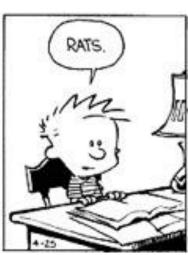


Jullie kunnen nu de opdrachten van les 13 maken











Institute for Life Science & Technology